Reporte para el dataset de Apps:

En el dataset se analizan 9659 apps, con 13 variables diferentes. De los datos se tiene que las variables estadisticas del dataset princiaples, el raiting promedio de las apps es 4.1 con una desvicion de 0.5, el tamano promedio de una app son 20.39 mb con una desviacion de 21.82, aqui surge la duda de apps con tamano de cero que se pueden tratar de apps con size de rango en Kilobytes.

Las categorias con mas presencia en el las tiendas son Family, Game y Tools. Las que tienen menos presencia son las categorias de Prenting, Comics y Beuty. Si una empresa quiere crear su app, es buena idea tener definida la categoria para lograr posicionarla. Por ejemplo si es una empresa de cosmeticos seria mas facil poscionarla en la categoria de Beuty que en la de family ya que en esta hay mas apps.

El promedio de calificación de las aplicaciones es de 4.17. Esto se observa como el promedio se distribuye alrededor de 4-5.

Apps gratis:
- El tamano de las app ronda alrededor de los 20 MB.
- Su raiting se encuentra alrededor del promedio general de las apps
- Se concentran mas en la parte de bajo tamano y alto raiting

Apps de pago:
- En la grafica se observa que estas apps tienen en su mayoria un tamano menor de 50MB o alrededor de 400MB
- El raiting se encuentra entre 4.0-4.5

Las categorias que presentan un cobro mas alto son Finance, Lifestyle y Family. En general, se obseva que las apps gratis tienen mayor numero de desacragas frente a las apps de cobro. Por otro lado la percepcion de los sentimientos, tiene mas outliers en las apps gratis. Esto se debe a que la cantidad de apps gratis descargadas frente a apps de pago es ronda un rango de 7 a 100, por lo que hay mas usuarios que pueden hacer la prueba.

Para concluir este analisis sobre aplicaciones en la PlayStore. Si una empresa o un cliente quisiera lanzar una app en esta tienda se le comentarian los siguientes puntos a tener en consideracion:
- El rango promedio del tamano de una es 20MB
- Definir que categoria corresponde la aplicacion, si es de nicho tendra menos competidores y tendra menos competidores, que si es de un proposito mas general o pertenece a las categorias con mas apps
- Otra caracteristica importante es si la app sera de pago o gratis, dependiendo del enfoque del negocio.
- Considerar estas variables antes de lanzar una app a la tienda puede ayudar al necio si es conveniente o no.
- Por ultimo tambien es importante tener en cuenta la naturaleza del negocio y a que sector va dirigido, si solo se va a lanzar a otras plataforma como AppStore o GalleyApp, donde los usuarios tienen diferentes comportamientos.

Reporte para el dataset de HeartAttack:

El EDA tiene las siguientes caracteristicas:

- 14 variables del, 5 numericas y 9 categoricas
- La muestra tiene desbalance en la categoria 200 hombres y 100 mujeres
- El valor promedio del colesterol en el dataset es 246, que ya es considerado un nivel alto, ver [1]
- El valor de azucar en ayunas (fbs), permite ver que en el data set la mayoria no tiene diabetes

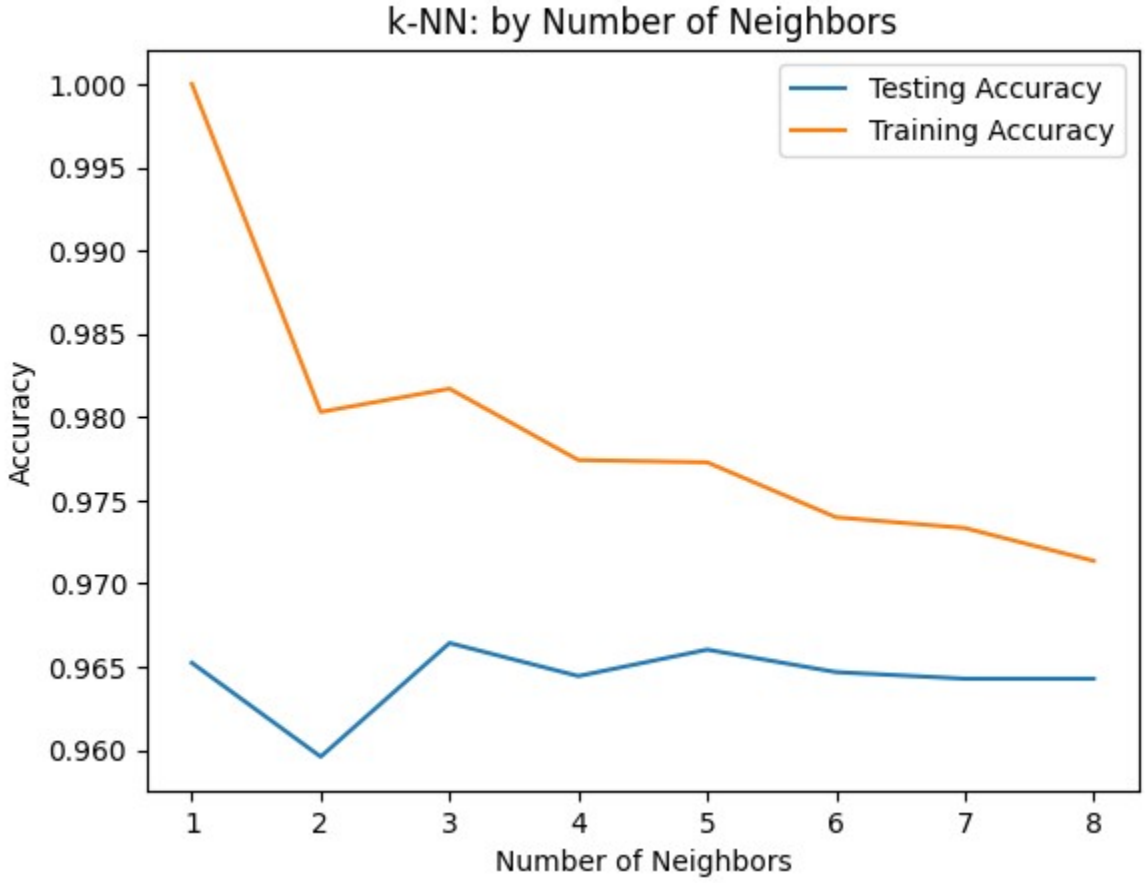
Las variables que tienen mas correlacion, ya sea negativa o positiva > 0.3, con el resultados de salida son:

- Chest pain (cp = 0.43)
- Max heart rate (thalachh = 0.35)
- Exercise induced angina (exng = -0.44)
- Previous peak (oldpeak = -0.36)
- Slope (slp = 0.36)
- Number of mayor vessels (caa = -0.43)
- ThaliumStress Test result (thall = -0.39)

Esto nos dice que las variables que pueden influir mas en el resultados son las anteriores.

El score de la prediccion es de 0.75 para el modelo de knn vecinos.

Reporte para MNIST data set



En la grafica de Accuracy vs Number of Neighbors se observa que si aumenta el numero de vecinos en los datos de entreanemiento el accuracy disminuye, pero el en los datos de prueba a partir 5 el accuracy se mantiene constante, en esta grafica en los datos de prueba el valor optimo de knn = 3.

Las predicciones en los dos modelos es acertada, en ambos casos se acerto el numero 7. Pero la ventaja de regresion logistica es que una vez entrenado el modelo la prediccion sera mas rapida que con knn, como el data set de entrenamiento es muy grande y con muchas variables las prediciones pueden ser mas lentas.

[1] https://medlineplus.gov/spanish/cholesterollevelswhatyouneedtoknow.html